- Create internal and external customer tables and load data into them.

1. إنشاء الجدول الداخلي: قمت بتعريف هذا الجدول ليكون تحت الإدارة المباشرة لمحرك معالجة البيانات (هايف) حيث يتولى النظام مسؤولية تنظيم البيانات وتخزينها في المستودع الافتراضي وقمت بتحميل البيانات الى الجدول:

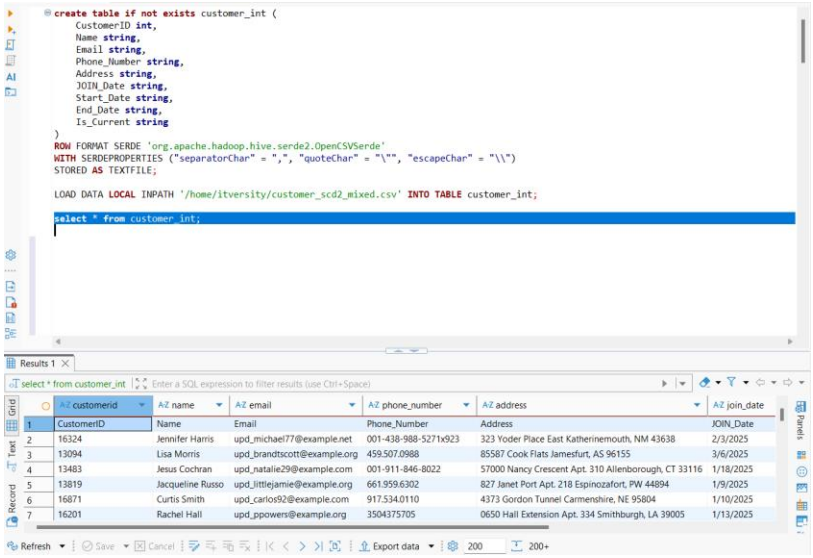

```
create table if not exists customer_int (
    CustomerID int,
    Name string,
    Email string,
    Phone_Number string,
    Address string,
    JOIN_Date string,
    Start_Date string,
    End_Date string,
    Is_Current string
)
ROW FORMAT SERDE 'org.apache.hadoop.hive.serde2.OpenCSVSerde'
WITH SERDEPROPERTIES ("separatorChar" = ",", "quoteChar" = "\"", "escapeChar" = "\\")
STORED AS TEXTFILE;

LOAD DATA LOCAL INPATH '/home/itversity/customer_scd2_mixed.csv' INTO TABLE customer_int;

select * from customer_int;
```

Results 1

select * from customer_int

customerid	name	email	phone_number	address	join_date
CustomerID	Name	Email	Phone_Number	Address	JOIN_Date
16324	Jennifer Harris	upd_michael77@example.net	001-438-988-5271x923	323 Yoder Place East Katherinemouth, NM 43638	2/3/2025
13094	Lisa Morris	upd_brandtscott@example.org	459.507.0988	85587 Cook Flats Jamesfurt, AS 96155	3/6/2025
13483	Jesus Cochran	upd_natalie29@example.com	001-911-846-8022	57000 Nancy Crescent Apt. 310 Allenborough, CT 33116	1/18/2025
13819	Jacqueline Russo	upd_littlejamie@example.org	661.959.6302	827 Janet Port Apt. 218 Espinozafort, PW 44894	1/9/2025
16871	Curtis Smith	upd_carlos92@example.com	917.534.0110	4373 Gordon Tunnel Carmenshire, NE 95804	1/10/2025
16201	Rachel Hall	upd_ppowers@example.org	3504375705	0650 Hall Extension Apt. 334 Smithburgh, LA 39005	1/13/2025

2. إنشاء الجدول الخارجي: قمت ببناء هذا الجدول مع تحديد موقع تخزين مخصص له في نظام HDFS والهدف من ذلك هو فصل هيكل الجدول البرمجي عن الملفات الخام مما يضمن لي بقاء البيانات محفوظة حتى لو قمت بحذف الجدول من النظام وقمت بتحميل البيانات الى الجدول:

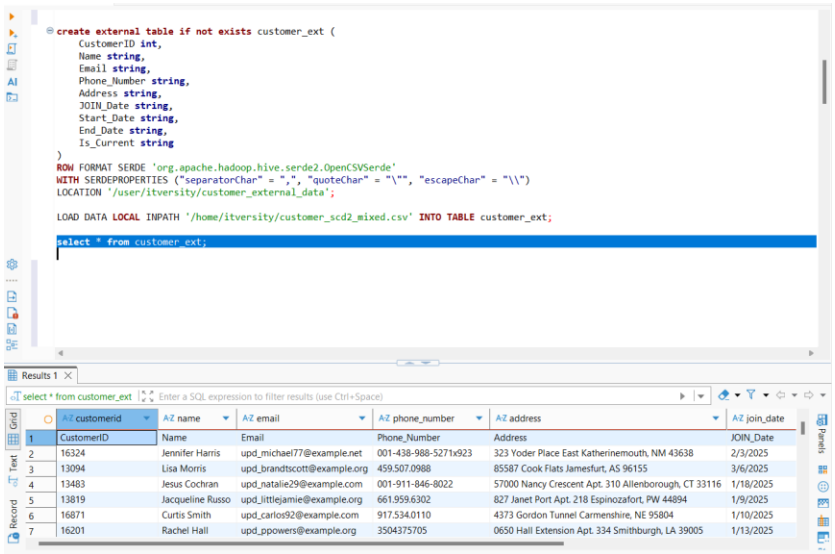

```
create external table if not exists customer_ext (
    CustomerID int,
    Name string,
    Email string,
    Phone_Number string,
    Address string,
    JOIN_Date string,
    Start_Date string,
    End_Date string,
    Is_Current string
)
ROW FORMAT SERDE 'org.apache.hadoop.hive.serde2.OpenCSVSerde'
WITH SERDEPROPERTIES ("separatorChar" = ",", "quoteChar" = "\"", "escapeChar" = "\\")
LOCATION '/user/itversity/customer_external_data';

LOAD DATA LOCAL INPATH '/home/itversity/customer_scd2_mixed.csv' INTO TABLE customer_ext;

select * from customer_ext;
```

Results 1

select * from customer_ext

customerid	name	email	phone_number	address	join_date
CustomerID	Name	Email	Phone_Number	Address	JOIN_Date
16324	Jennifer Harris	upd_michael77@example.net	001-438-988-5271x923	323 Yoder Place East Katherinemouth, NM 43638	2/3/2025
13094	Lisa Morris	upd_brandtscott@example.org	459.507.0988	85587 Cook Flats Jamesfurt, AS 96155	3/6/2025
13483	Jesus Cochran	upd_natalie29@example.com	001-911-846-8022	57000 Nancy Crescent Apt. 310 Allenborough, CT 33116	1/18/2025
13819	Jacqueline Russo	upd_littlejamie@example.org	661.959.6302	827 Janet Port Apt. 218 Espinozafort, PW 44894	1/9/2025
16871	Curtis Smith	upd_carlos92@example.com	917.534.0110	4373 Gordon Tunnel Carmenshire, NE 95804	1/10/2025
16201	Rachel Hall	upd_ppowers@example.org	3504375705	0650 Hall Extension Apt. 334 Smithburgh, LA 39005	1/13/2025

- Notice the issue related to delimiter inside the address column value, find a solution to make hive read the file properly without changing the separator. (Do some web search)

بالنسبة لمشكلة الفواصل في العنوان قمت بالبحث في الذكاء الاصطناعي عن أفضل الحلول البرمجية ووجدت أن استخدام مكتبة (OpenCSVSerde) هو الحل الأنسب تكمن قوة هذا الحل في قدرته الذكية على تمييز الرموز لذلك قمت بضبط إعدادات الجدول ليتجاهل أي فاصلة تقع بين علامتي تنصيص ويعتبرها جزءاً من النص وليس فاصلاً بين الحقول:

```
ROW FORMAT SERDE 'org.apache.hadoop.hive.serde2.OpenCSVSerde'
WITH SERDEPROPERTIES (
    "separatorChar" = ",",
    "quoteChar"     = "\"",
    "escapeChar"    = "\\"
)
```

المترجم (OpenCSVSerde):

هو القارئ المتخصص الذي استخدمناه بدلاً من القارئ الافتراضي ويتميز بقدرته العالية على معالجة ملفات النصوص التي تحتوي على تداخل في الرموز أو تعقيدات في النصوص الطويلة مثل العناوين

فاصل الحقول (separatorChar):

يحدد الرمز المستخدم للفصل بين عمود وآخر داخل الملف وفي حالتنا قمنا بضبطه على الفاصلة (,) لتتوافق مع بنية ملفات CSV

رمز الاقتباس (quoteChar):

يخبر المحرك بأن أي نص يقع بين علامتي تنصيص ("") يجب معالجته ككتلة واحدة وبالتالي يتم تجاهل أي فاصلة موجودة داخل هذه العلامات وعدم اعتبارها فاصلاً للأعمدة

رمز الهروب (escape Char):

يستخدم رمز الخط المائل الخلفي (\) لتعريف النظام بأن الرمز الذي يليه مباشرة هو نص عادي وليس له دلالة برمجية مما يضمن استقرار قراءة السجلات حتى في حال وجود رموز خاصة ومعقدة

- Try to drop both external and internal tables and notice what happens to the data.

1. عند حذف الجدول الداخلي (customer_int):

لاحظت أن نظام هايف قام بحذف هيكل الجدول من قاعدة البيانات وبالتوازي مع ذلك قام بحذف الملفات الفعلية من نظام الملفات الموزع HDFS هذا يعني أن البيانات ضاعت تماماً بمجرد حذف الجدول

2. عند حذف الجدول الخارجي (customer_ext):

كانت النتيجة مختلفة حيث قام النظام بحذف تعريف الجدول فقط من واجهة DBeaver بينما بقيت البيانات الفعلية محفوظة وسليمة في مسارها المحدد داخل HDFS هذا يثبت أن البيانات في الجداول الخارجية تظل محمية ومستقلة

الجداول قبل الحذف:

```
itversity@itvdelab: ~
itversity@itvdelab:~$ hdfs dfs -ls /user/hive/warehouse/customer_int
Found 1 items
-rw-r--r--   1 itversity supergroup      28979 2026-05-07 21:25 /user/hive/warehouse/customer_int/customer_scd2_mixed.csv
itversity@itvdelab:~$ hdfs dfs -ls /user/itversity/customer_external_data
Found 1 items
-rw-r--r--   1 itversity supergroup      28979 2026-05-07 21:29 /user/itversity/customer_external_data/customer_scd2_mixed.csv
itversity@itvdelab:~$
```

الجداول بعد الحذف:

```
itversity@itvdelab: ~
itversity@itvdelab:~$ hdfs dfs -ls /user/hive/warehouse/customer_int
ls: `/user/hive/warehouse/customer_int': No such file or directory
itversity@itvdelab:~$ hdfs dfs -ls /user/itversity/customer_external_data
Found 1 items
-rw-r--r--   1 itversity supergroup      28979 2026-05-07 21:29 /user/itversity/customer_external_data/customer_scd2_mixed.csv
itversity@itvdelab:~$
```

الاستنتاج حسب فهمي:

الجداول الخارجية هي الخيار الأكثر أماناً في بيئات العمل الضخمة للحفاظ على سلامة البيانات بينما تستخدم الجداول الداخلية للبيانات المؤقتة أو التي تدار كلياً داخل بيئة العمل

- Create customer dimension (Slowly changing dimension type 2) as “customer_scd2_mixed.csv” file.

معالجة البيانات: قمت بتحميل ملف customer_scd2_mixed.csv الذي يحتوي على مزيج من السجلات الحالية والتاريخية وكذلك يدعم ال SCD TYPE 2 وبفضل استخدام أوبن سي إس في سيردي تمكنت من استيراد العناوين المعقدة والتواريخ

```
create table if not exists customer_dim (
    CustomerID int,
    Name string,
    Email string,
    Phone_Number string,
    Address string,
    JOIN_Date string,
    Start_Date string,
    End_Date string,
    Is_Current string
)
ROW FORMAT SERDE 'org.apache.hadoop.hive.serde2.OpenCSVSerde'
WITH SERDEPROPERTIES ("separatorChar" = ",", "quoteChar" = "\"", "escapeChar" = "\\")
STORED AS TEXTFILE;

LOAD DATA LOCAL INPATH '/home/itversity/customer_scd2_mixed.csv' INTO TABLE customer_dim;


select CustomerID, Name, Address, Start_Date, End_Date, Is_Current
from customer_dim
order by CustomerID, Start_Date;
```

Results 1

select CustomerID, Name, Address, Start_Date | Enter a SQL expression to filter results (use Ctrl+Space)

	customerid	name	address	start_date	end_date	is_current
1	12364	Larry Hess	556 Schmidt Gateway Apt. 111 Kaneton, NM 59573	4/1/2025		1
2	12402	John Robinson	USNV Wagner FPO AA 72667	4/1/2025		1
3	12424	Trevor Brewer	56957 Jeanne Cove Suite 783 Krystalfort, PW 47290	4/1/2025		1
4	12455	Chad Hubbard	5145 Joshua Plain Apt. 820 Michaelland, AK 78543	4/1/2025		1
5	12461	Christina Lam	80779 Duke Drive South Franklin, IL 66035	4/1/2025		1
6	12473	Brian Lucas	32286 Christopher Stravenue West Lauren, MH 63912	4/1/2025		1
7	12512	Daniel Rogers	Unit 5034 Box 1825 DPO AA 73143	4/1/2025		1
8	12515	John Ray	99279 Jones Harbor South Alexanderport, CO 21816	4/1/2025		1

Refresh Save Cancel Export data 200 200+

- Use “customer_updated.csv” file to insert new data with end_date = null and is_current = ‘1’ and update changed data to be with end_date and is_current = “0” to track history.

- “Hive doesn’t support update or deletes so find a work around to make this SCD type 2 without using Transactional tables”

طريقة الحل:

أولاً: إنشاء جدول Staging Table:

تم إنشاء جدول مؤقت تحت مسمى customer_stage ليكون الوعاء الأول لاستقبال البيانات الخام القادمة من ملف customer_updated.csv

```
create table if not exists customer_stage (
    CustomerID int,
    Name string,
    Email string,
    Phone_Number string,
    Address string,
    JOIN_Date string
)
ROW FORMAT SERDE 'org.apache.hadoop.hive.serde2.OpenCSVSerde'
WITH SERDEPROPERTIES ("separatorChar" = ",", "quoteChar" = "\"", "escapeChar" = "\\");

LOAD DATA LOCAL INPATH '/home/itversity/customer_updated.csv' INTO TABLE customer_stage;

select * from customer_stage;
```

select * from customer_stage

	customerid	name	email	phone_number	address	join_date
1	CustomerID	Name	Email	Phone_Number	Address	JOIN_Date
2	12346	Debra Wells	michaelkerr@example.net	3317035462	USNV Olsen FPO AA 43254	2025-02-10
3	12347	Michael Grimes	rchandler@example.net	243.521.3090	36923 Bowers Gateway Suite 027 New Kristi, MP 44312	2025-03-14
4	12348	Jennifer Cuevas	brandonbrown@example.com	+1-863-584-5200x273	095 Stevenson Lodge New Brettville, LA 67557	2025-01-03
5	12349	Anthony Harvey	dgonzales@example.net	771-305-3764x583	549 Taylor Mews Baileyburgh, NJ 59083	2025-04-01
6	12350	Thomas Martin	longpatricia@example.net	558-648-9504x3880	294 Patricia Light Suite 377 Marymouth, GA 49741	2025-02-07
7	12352	James Bush	dennis40@example.net	+1-650-456-4394x097	44332 Janet Cliffs Apt. 178 Johnsonfort, WA 55056	2025-03-02

من خلال دمج المسارات الأربعة التي سيتم ذكرها في الصفحات القادمة تم استخدام عملية Union All واستخدام ال Insert Overwrite في بناء نظام تتبع البيانات تاريخيه من نوع SCD Type 2

ثانياً: المسارات المنطقية الأربعة لمعالجة البيانات:

1. الحفاظ على السجلات التاريخية (Save Historical Data):

في هذا المسار، يتم استرجاع كافة السجلات التي انتهت صلاحيتها سابقاً، أي التي تحمل الحالة is_current = 0 الهدف هو ضمان بقاء سجلات الغير نشطة محفوظة في النظام للرجوع إليها

```
insert overwrite table customer_dim

select
    customerid, name, email, phone_number, address, join_date, start_date, end_date, is_current
from customer_dim
where is_current = '0'

union all
```

Results 1

select customerid, name, email, phone_numb | Enter a SQL expression to filter results (use Ctrl+Space)

customerid	name	email	phone_number	address	join_date

2. الحفاظ على السجلات الحالية غير المتغيرة (Save Unchanged Current Records):

قمت بتصميم منطق برمجي يبحث عن العملاء الذين لم تطرأ أي تعديلات على بياناتهم في ملف customer_stage هذه السجلات يتم إعادة إدراجها كما هي لتظل نشطة مما يحافظ على استمرارية البيانات التي لم تتأثر بعملية التحديث الحالية

```
select
    d.customerid, d.name, d.email, d.phone_number, d.address, d.join_date, d.start_date, d.end_date, d.is_current
from customer_dim d
left join customer_stage s ON d.customerid = s.customerid
where d.is_current = '1'
  AND (
      s.customerid is null
      OR (
          d.name = s.name
          AND d.email = s.email
          AND d.phone_number = s.phone_number
          AND d.address = s.address
      )
  )

union all
```

Results 1

select d.customerid, d.name, d.email, d.phone | Enter a SQL expression to filter results (use Ctrl+Space)

	customerid	name	email	phone_number	address	join_date
1	18288	Isaiah Smith	new_georgepayne@example.com	7064907772	6035 Duane Forks Suite 497 Tammyport, OR 66373	2/16/2025
2	18289	Maria Ramirez	new_shannon12@example.org	+1-293-794-0945x58976	012 Lewis Parks Suite 183 Morganview, WV 02412	3/4/2025
3	18290	Heather Pierce	new_lyonsmadison@example.org	+1-799-247-2783x472	95517 Harper Forks Suite 831 Chelseabury, FM 95367	2/25/2025
4	18291	Brian Cameron	new_bryanaguilar@example.net	001-439-886-4343x6885	206 Jared Crescent Suite 816 Kaylashire, HI 36923	1/29/2025
5	18292	Miguel Powell	new_jose15@example.com	966-214-4300	26324 Evans Ville Olsonview, IA 38997	3/29/2025
6	18293	Jessica Barnes	new_igallegos@example.net	588-701-6979x681	03762 Sheila Ville Apt. 550 North Julieville, OK 22203	2/28/2025

3. الحفاظ على السجلات المعدلة - إغلاق السجل القديم (Expiring Modified Records):

عند اكتشاف اختلاف في بيانات عميل موجود مسبقاً يقوم النظام برمجياً بضبط تاريخ الانتهاء end_date على تاريخ اليوم الحالي وتغيير حالة السجل إلى is_current = 0

```sql
select
    d.customerid, d.name, d.email, d.phone_number, d.address, d.join_date, d.start_date,
    date_format(current_date(), 'yyyy-MM-dd') as end_date,
    '0' as is_current
from customer_dim d
join customer_stage s ON d.customerid = s.customerid
where d.is_current = '1'
  AND (
      d.name != s.name
      OR d.email != s.email
      OR d.phone_number != s.phone_number
      OR d.address != s.address
  )

union all
```

Results 1

select d.customerid, d.name, d.email, d.phone | Enter a SQL expression to filter results (use Ctrl+Space)

	customerid	name	email	phone_number	address	join_date
1	12364	Larry Hess	upd_meyerjennifer@example.com	001-626-971-5766	556 Schmidt Gateway Apt. 111 Kaneton, NM 59573	2/11/2025
2	12402	John Robinson	upd_sandrarice@example.net	919.380.4487x128	USNV Wagner FPO AA 72667	1/30/2025
3	12424	Trevor Brewer	upd_terri28@example.com	(395)241-5789x56943	56957 Jeanne Cove Suite 783 Krystalfort, PW 47290	2/7/2025
4	12455	Chad Hubbard	upd_tracy28@example.net	001-988-255-3862x492	5145 Joshua Plain Apt. 820 Michaelland, AK 78543	2/3/2025
5	12461	Christina Lam	upd_samuel91@example.net	+1-657-729-1463x3734	80779 Duke Drive South Franklin, IL 66035	3/24/2025
6	12473	Brian Lucas	upd_alexanderellis@example.org	-5790	32286 Christopher Stravenue West Lauren, MH 63912	3/29/2025

4. إدراج البيانات الجديدة والنسخ المحدثة (Inserting New and Updated Records):

في المسار الأخير يتم إضافة العملاء الجدد الذين يظهرون لأول مرة وكذلك إضافة النسخ المحدثة للعملاء الذين تغيرت بياناتهم في الخطوة السابقة

```sql
select
    s.customerid, s.name, s.email, s.phone_number, s.address, s.join_date,
    date_format(current_date(), 'yyyy-MM-dd') as start_date,
    null as end_date,
    '1' as is_current
from customer_stage s
left join customer_dim d ON s.customerid = d.customerid AND d.is_current = '1'
where d.customerid is null
   OR (
      d.name != s.name
      OR d.email != s.email
      OR d.phone_number != s.phone_number
      OR d.address != s.address
   );
```

Results 1

select s.customerid, s.name, s.email, s.phone_ | Enter a SQL expression to filter results (use Ctrl+Space)

	customerid	name	email	phone_number	address	join_date
1	CustomerID	Name	Email	Phone_Number	Address	JOIN_Date
2	12346	Debra Wells	michaelkerr@example.net	3317035462	USNV Olsen FPO AA 43254	2025-02-10
3	12347	Michael Grimes	rchandler@example.net	243.521.3090	36923 Bowers Gateway Suite 027 New Kristi, MP 44312	2025-03-14
4	12348	Jennifer Cuevas	brandonbrown@example.com	+1-863-584-5200x273	095 Stevenson Lodge New Brettville, LA 67557	2025-01-03
5	12349	Anthony Harvey	dgonzales@example.net	771-305-3764x583	549 Taylor Mews Baileyburgh, NJ 59083	2025-04-01
6	12350	Thomas Martin	longpatricia@example.net	558-648-9504x3880	294 Patricia Light Suite 377 Marymouth, GA 49741	2025-02-07